


以機器學習預測 口腔癌篩檢異常結果

Oral Cancer Screening Abnormality Prediction Using Machine Learning

曾建瑋 (611421501) | 115b 機器學習 (NDHU) [期末專題簡報](#)





專案動機

台灣口腔癌發生率長年位居男性癌症前五名。根據國健署引用的本土研究（高雄醫學大學葛應欽教授團隊），吸菸者罹癌風險約為一般人 **18 倍**、嚼檳榔者約 **28 倍**、飲酒者約 **10 倍**；菸與檳榔並存風險驟升至 **89 倍**，三者皆有甚至高達 **123 倍**。

政府提供 30 歲以上（原住民 18 歲以上）有吸菸或嚼檳榔習慣者每兩年一次免費口腔黏膜篩檢，但並非所有符合資格者都會被即時識別與轉介，導致高風險族群可能錯過早期發現機會。

- ① 本專題以機器學習**預先標出高風險個案**，協助醫療人員排定轉介優先順序，同時**避免「轉介疲勞」**——讓主動轉介真正落實，而非淪為形式。

專案目標

任務型態

二元分類 (Binary Classification)

預測目標：篩檢結果是否異常 (1=異常 / 0=正常)

核心驗證問題

比較至少 3 種演算法，找出在「**不漏掉真正異常個案**」與「**整體判別能力**」之間表現最佳的模型

僅憑基礎人口與生活習慣資料，是否足以有效識別高風險個案？



資料集說明

資料來源

花蓮慈濟醫院四癌篩檢資料庫（機構自有資料，非公開下載）

已取得授權並完成去識別化；本人自行從院內資料庫系統匯出

資料規模與組成

共 **21,034** 筆，涵蓋近 10 年篩檢紀錄

格式：10 個特徵 + 1 個 Label，CSV 格式

類別分布

正常約 **78.6%**、異常約 **21.4%**（約 3.7：1）

存在明顯類別不平衡，為建模的主要挑戰之一

特徵欄位

特徵	類型
年齡、篩檢年份	數值
吸菸／嚼檳榔強度	有序數值（0–5）
性別、是否原住民、自覺口腔不適	二元
累計篩檢次數、上次結果、距上次年數	數值／二元

 **標籤：**0=正常；1=異常（白斑、紅斑、疑似口腔癌等）

備註：其中 screening_year 為計算用中介欄位，實際送入模型的特徵為 9 個

資料前處理

01

去識別化與日期轉換

病歷號以 `pd.factorize()` 轉為匿名流水號；民國年格式換算為西元年，計算年齡與篩檢年份

03

衍生特徵工程

依病患歷史計算「累計篩檢次數」「上次篩檢結果」「距上次篩檢年數」三個新特徵

02

類別編碼與缺漏值處理

篩檢結果代碼 00→正常(0)、其餘→異常(1)；數值欄位以中位數填補，生活習慣欄位填 0，性別以眾數填補

04

資料切割、標準化與不平衡處理

80/20 分層抽樣切割；StandardScaler 僅在訓練集 fit；對訓練集做 SMOTE 過採樣，並搭配 `class_weight="balanced"` 雙重處理類別不平衡

模型建構

選用 4 個分屬不同演算法類型的模型進行跨類型比較，四模型皆設定 `class_weight="balanced"` 與 `random_state=42`：



Random Forest（集成學習）

`n_estimators=100, max_depth=10`

多棵樹投票，處理非線性交互作用，可輸出 Feature Importance



Logistic Regression（線性模型）

`C=1.0`

醫療研究最常用的基準模型，係數可直接解釋風險因子貢獻



SVM（RBF kernel）

`C=1.0`

將資料映射至高維空間做非線性分類，與線性、樹狀模型形成對照



Decision Tree（樹狀模型）

`max_depth=8`


結構最直觀，適合視覺化呈現決策邏輯

效能評估：Accuracy 與混淆矩陣

四模型在 4,207 筆測試集（正常 3,305 / 異常 902）上的表現：

模型	Accuracy	Precision	Recall	F1	AUC
Random Forest	0.6855	0.3241	0.4302	0.3697	0.6300
Logistic Regression	0.6404	0.2841	0.4457	0.3470	0.6058
SVM	0.6477	0.2994	0.4800	0.3688	0.6249
Decision Tree	0.6910	0.3260	0.4135	0.3646	0.6160

⚠️ 混淆矩陣關鍵觀察：四模型的 False Negative（漏報）皆偏高（469～529），是目前最大弱點。Decision Tree 雖 Accuracy 最高，但漏報最多——顯示在類別不平衡資料中，Accuracy 不能單獨作為判斷依據。



效能評估：ROC 曲線與 AUC

AUC 排序



Random Forest

AUC = 0.630，綜合最佳



SVM

AUC = 0.625



Decision Tree

AUC = 0.616



Logistic Regression


AUC = 0.606

關鍵解讀

四模型 AUC 介於 **0.606~0.630**，皆明顯優於隨機猜測（AUC=0.5），但離「優良判別力」（AUC $\geq$ 0.7）仍有差距。

四條 ROC 曲線高度重疊，顯示在僅有人口特徵與生活習慣資料的條件下，四種演算法的判別能力相近。

❏ 模型選擇造成的差異，小於資料本身資訊量的限制。



模型比較與分析

「最佳模型」取決於採用的指標，這正是分析的重點：



Random Forest

F1/AUC 最佳，綜合判別力最強；但模型為黑箱，訓練與部署成本較高



SVM

Recall 最高 (0.48)，最符合「不能漏掉異常」的醫療優先序；但訓練最慢、可解釋性低



Logistic Regression

最具可解釋性，適合作為臨床基準；但**多數指標**在四模型中最低（Recall 例外，仍優於 Decision Tree）



Decision Tree

結構最直觀，易視覺化；但容易漏掉異常個案，對資料變動較敏感

i 結論：Random Forest 與 SVM 互為候選最佳模型，醫療情境應優先參考 Recall，選擇應對齊應用場景的代價結構。

特徵重要性分析

以 Random Forest 的特徵重要性排序，前三名合計貢獻約 76% 的重要性：

32%

嚼檳榔強度

重要性最高，驗證生活習慣因子的核心地位

27%

年齡

重要性高於原先預期，僅次於嚼檳榔

17%

吸菸強度


第三大風險因子，與政策邏輯吻合

3%

上次篩檢結果

實際重要性偏低，低於原先預期

嚼檳榔、吸菸、年齡恰好也是目前篩檢資格認定的核心條件，模型結果與既有政策邏輯相互呼應，具備作為「主動辨識高風險個案」初步篩選規則的潛力。



成果展示與推論系統 Demo

已產出四張視覺化圖表（混淆矩陣、ROC 曲線、特徵重要性、篩檢異常部位分布）。異常部位代碼「B」遠超其他部位（約 **2,150** 次，第二名約 280 次），顯示異常案例高度集中於特定部位。

案例一：低風險

55 歲、女性，不吸菸、嚼檳榔已戒、無自覺口腔不適、過去 3 次篩檢皆正常、距上次篩檢已 6 年

→ 預測「**正常**」，異常機率 **16.3%**

案例二：高風險


45 歲、男性，現有吸菸與嚼檳榔習慣、自覺口腔不適、上次篩檢曾有異常紀錄

→ 預測「**異常（建議轉介）**」，異常機率 **72.2%**

決策門檻由預設 0.5 調降至 **0.35**，反映「醫療情境寧可多通知、不要漏掉」的權衡考量。提供 Google Colab Notebook 可重現完整流程。


```
18 # 步驟 1: 資料前處理
19 # 載入原始 CSV → 去識別化 → 日期轉換 → 欄位重命名
20 # → 類別編碼 → 缺漏值處理 → 衍生特徵計算
21 # → 訓練/測試集切割 → 標準化 → SMOTE 過採樣
22 #
23 print("\n=== 步驟 1: 資料前處理 ===")
24 X_train, X_test, y_train, y_test, feature_cols, scaler = preprocess.run_preprocessing()
25
26 #
27 # 步驟 2: 建立模型
28 # 依照 config.py 的超參數, 初始化四個分類器物件:
29 # Random Forest, Logistic Regression, SVM, Decision Tree
30 #
31 print("\n=== 步驟 2: 建立模型 ===")
32 model_dict = models.build_models(config.RANDOM_STATE)
33
34 #
35 # 步驟 3: 訓練模型
36 # 用訓練集 (X_train, y_train) 訓練四個模型分別輸出 z1, z2, z3, z4
```

▶ 02:50



機器學習期末報告影片



程式架構導覽

[config.py](#)：集中管理設定（欄位對照、模型超參數、檔案路徑）

src/[models.py](#)：模型建構模組

[main.py](#)：整合上述模組，依序執行完整 pipeline（對應前處理→建模→評估 7 個步驟）

src/[preprocess.py](#)：資料前處理模組

src/[evaluate.py](#)：效能評估模組

predict.py / [demo_predict.py](#)：載入訓練好的模型，對單筆病患資料推論

模組化設計使各步驟可獨立測試與替換，維護性高。

結語與未來方向

本專題完成 4 個機器學習模型的建構與系統化比較（超過課程要求的至少 3 個），四模型 AUC 達 **0.61~0.63**，驗證基礎人口與生活習慣資料具備初步辨識高風險個案的能力。嚼檳榔強度、年齡、吸菸強度為三大關鍵風險因子，與現行篩檢資格政策高度吻合。

⚠️ 準備 Demo 過程中的重要發現：模型對部分「直覺上應屬低風險」的組合仍可能輸出偏高的異常機率。原因在於 SMOTE 過採樣可能扭曲稀疏特徵空間區域的決策邊界，屬「機率校準 (probability calibration)」層面的限制，而非程式錯誤。

→ 導入機率校準層

如 CalibratedClassifierCV，讓輸出機率更貼近真實比例

→ 系統化選擇判定門檻

以 Precision-Recall 曲線取代目前依經驗設定的 0.35

→ 標示低信心案例

對少見特徵組合標示「低信心、建議人工複核」，落實模型為輔助分診工具的核心定位

感謝聆聽，請多指教 🙏